Analyse en composantes principales

STT-2200

Steven Golovkine

Automne 2026

Université Laval

Représenter les données

Sélection de variables et nouvelles coordonnées

Sélection de variables

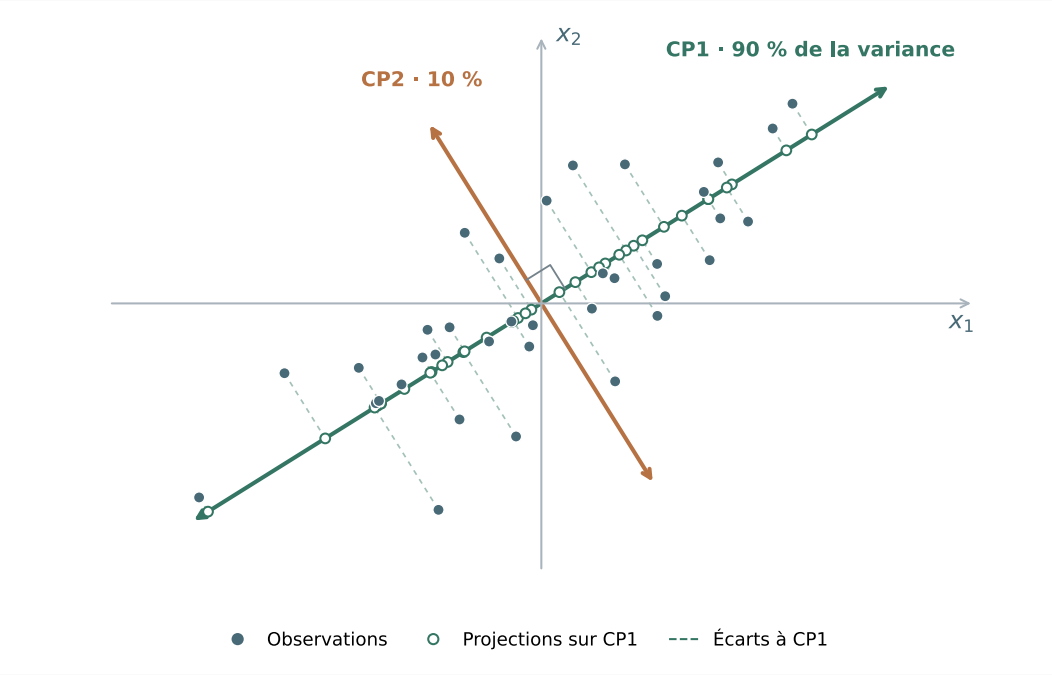
Garder certaines variables originales.
Exemple : conserver uniquement la note de l'examen final.

Construction de composantes

Combiner les variables en quelques scores.
Exemple : résumer plusieurs évaluations par un niveau commun.

L'ACP construit de nouvelles coordonnées à partir de variables quantitatives.

Le principe géométrique de l'ACP



CP1 suit la direction de plus grande variance des projections.

CP2 lui est perpendiculaire et résume la variation restante.

Dans ces données simulées, CP1 conserve **90 %** de la variance.

Garder tous les axes change le repère. En supprimer réduit la dimension.

Centrer le nuage

$$z_{ij} = x_{ij} - \overline{x}_j, \quad \overline{x}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}$$

Effet géométrique

Le point moyen devient l'origine. Les distances entre observations restent identiques.

Exemple : une note sur 20

Si la moyenne vaut 12, une note de 14 donne une valeur centrée de 2 points.

ACP centrée ou centrée réduite

ACP centrée

$$z_{ij} = x_{ij} - \overline{x}_j$$

Analyse de la **covariance**.
Les variables les plus dispersées pèsent davantage.

ACP centrée réduite

$$z_{ij} = \frac{x_{ij} - \overline{x}_j}{s_j}$$

Analyse de la **corrélation**.
Chaque variance initiale vaut 1.

La standardisation est un choix d'analyse

Unités différentes

Le prix en dollars peut dominer la superficie d'un logement en mètres carrés.
Réduire supprime cet effet d'unité.

Poids des variables

Une variance égale à 1 donne autant de poids initial à une mesure peu fiable qu'à une mesure précise.

Le choix des variables et de leur échelle définit la géométrie analysée.

Construire les composantes

Données, directions et scores

Objet	Dimension	Interprétation
Z	$n \times p$	Données centrées, éventuellement réduites
α_k	$p \times 1$	Direction unitaire du k-ième axe
$Y_k = Z\alpha_k$	$n \times 1$	Scores des individus sur cet axe
A_q	$p \times q$	Les q directions conservées
$T_q = ZA_q$	$n \times q$	Tableau des coordonnées réduites

Les n observations ont le même poids. Les variances utilisent le diviseur $n - 1$.

Variance d'une projection

La covariance empirique des données centrées est

$$\hat{\Sigma} = \frac{1}{n-1} Z^\top Z.$$

Pour une direction unitaire α, le vecteur des scores est $y = Z\alpha$.

$$\mathrm{Var}(y) = \frac{1}{n-1} y^\top y = \alpha^\top \hat{\Sigma} \alpha.$$

La contrainte $\alpha^\top \alpha = 1$ fixe l'échelle : multiplier les coefficients par c multiplierait la variance par c^2.

Le premier axe : un problème d'optimisation

$$\alpha_1 = \arg\max_{\alpha^\top \alpha = 1} \alpha^\top \hat{\Sigma} \alpha$$

Le Lagrangien introduit la contrainte de norme :

$$\mathcal{L}(\alpha, \lambda) = \alpha^\top \hat{\Sigma} \alpha - \lambda(\alpha^\top \alpha - 1).$$

La condition de stationnarité donne

$$2\hat{\Sigma}\alpha - 2\lambda\alpha = 0 \quad \Rightarrow \quad \hat{\Sigma}\alpha = \lambda\alpha.$$

Les directions candidates sont les vecteurs propres de la covariance.

Pourquoi choisir la plus grande valeur propre ?

Par le théorème spectral, $\hat{\Sigma}$ possède une base orthonormée $(u_1, ..., u_p)$ et des valeurs propres $\lambda_1 \geq ... \geq \lambda_p \geq 0$.

Pour tout vecteur unitaire, $\alpha = \sum_j c_j u_j$ avec $\sum_j c_j^2 = 1$.

$$\alpha^\top \hat{\Sigma} \alpha = \sum_{j=1}^{p} \lambda_j c_j^2 \leq \lambda_1.$$

La borne est atteinte avec $\alpha_1 = u_1$. Ainsi, $Y_1 = Z\alpha_1$ et $\mathrm{Var}(Y_1) = \lambda_1$.

Les axes suivants et la non-corrélation

L'axe k maximise la variance sous deux contraintes :

- $\alpha_k^\top \alpha_k = 1$;
- $\alpha_k^\top \alpha_j = 0$ pour tout $j < k$.

$$\hat{\Sigma}\alpha_k = \lambda_k \alpha_k, \quad Y_k = Z\alpha_k$$

$$\mathrm{Cov}(Y_k, Y_l) = \alpha_k^\top \hat{\Sigma} \alpha_l = \lambda_l \alpha_k^\top \alpha_l$$

La variance de Y_k vaut λ_k.

Les composantes sont non corrélées, ce qui n'implique pas leur indépendance.

Représentation réduite et rang

$$A_q = (\alpha_1 \mid \ldots \mid \alpha_q), \quad T_q = ZA_q, \quad A_q^\top A_q = I_q,$$

$$\frac{1}{n-1} T_q^\top T_q = \operatorname{diag}(\lambda_1, \ldots, \lambda_q).$$

Chaque ligne de T_q

Les q scores d'une observation :

$$y_{ik} = \sum_{j=1}^{p} \alpha_{jk} z_{ij}, k = 1, \ldots, q.$$

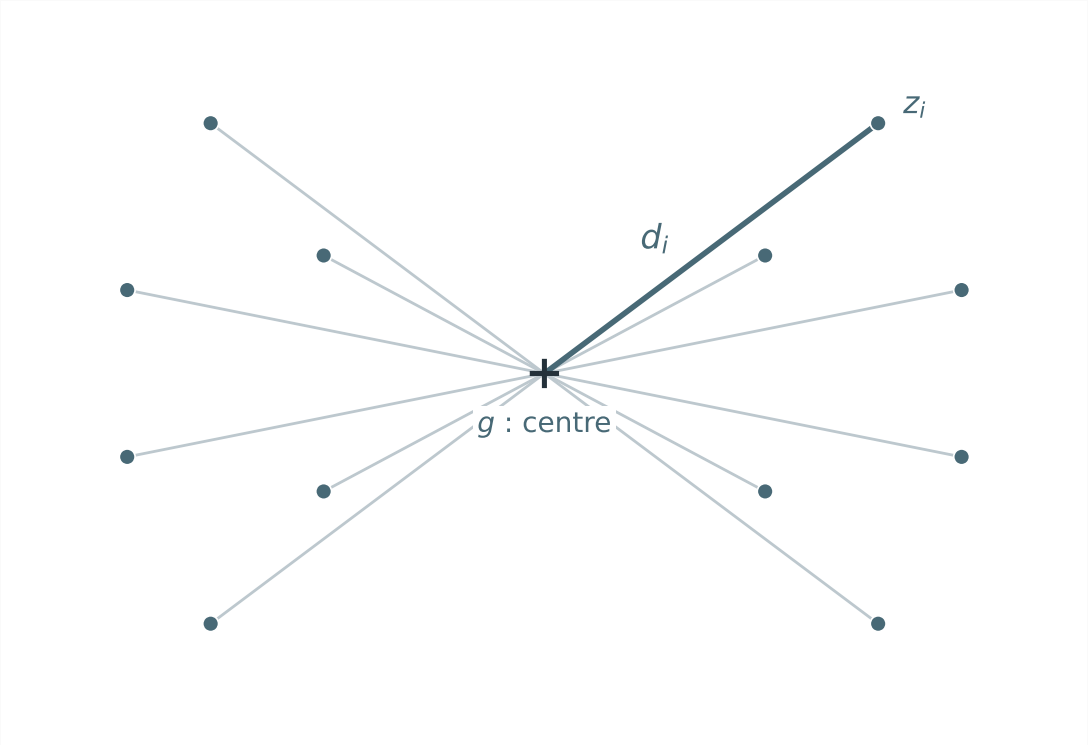
Nombre d'axes non nuls

Exactement r composantes ont une variance strictement positive.

$$r = \operatorname{rang}(Z) \leq \min(n-1, p).$$

Mesurer la variance conservée

L’inertie mesure la dispersion autour du centre



Pour des données centrées, $g = 0$.

$$I = \frac{1}{n-1} \sum_{i=1}^{n} \|z_i\|^2$$

Une distance deux fois plus grande apporte un terme quatre fois plus grand.

Avec une normalisation par n, l’inertie vaut $\frac{n-1}{n} I$. Les proportions de variance conservée restent identiques.

L’inertie est la somme des valeurs propres

$$I = \sum_{j=1}^{p} \mathrm{Var}(Z_j) = \mathrm{tr}\left(\hat{\Sigma}\right) = \sum_{k=1}^{p} \lambda_k$$

Changement de repère

$$\|z_i\|^2 = \sum_{k=1}^{p} y_{ik}^2.$$

L’orthonormalité conserve les distances et l’inertie totale.

ACP centrée réduite

Chaque variable a une variance égale à 1. L’inertie totale vaut donc

$$I = p.$$

Variance expliquée par un axe et par plusieurs axes

$$r_k = \frac{\lambda_k}{\sum_{j=1}^{p} \lambda_j}, \quad R_q = \frac{\sum_{k=1}^{q} \lambda_k}{\sum_{j=1}^{p} \lambda_j}.$$

Exemple

CP1 : 60 % ; CP2 : 22 %.
Le premier plan conserve 82% de la variance totale.

Part omise

Les 18 % restants correspondent à des différences invisibles dans ce plan.

« Expliquée » signifie conservée par la projection, sans interprétation causale.

Reconstruction et variance perdue

$$\hat{Z}_q = T_q A_q^\top, \quad \hat{z}_i = \sum_{k=1}^{q} y_{ik}\alpha_k,$$

$$\frac{1}{n-1}\sum_{i=1}^{n} \|z_i - \hat{z}_i\|^2 = \sum_{k=q+1}^{p} \lambda_k = I(1 - R_q)$$

Parmi les projections orthogonales de dimension q, l'ACP est celle qui minimise l'erreur quadratique de reconstruction.

Pour revenir aux unités originales : multiplier par s_j si les variables ont été réduites, puis ajouter $\overline{x}_j$.

Exemple : deux évaluations

Deux examens corrélés

Chaque étudiant est décrit par ses deux notes centrées réduites. On suppose une corrélation empirique de 0.8.

$$\hat{\Sigma} = \begin{pmatrix} 1 & 0.8 \\ 0.8 & 1 \end{pmatrix}, \quad \det\left(\hat{\Sigma} - \lambda I_2\right) = (1-\lambda)^2 - 0.8^2.$$

Première direction

$$\lambda_1 = 1.8, \quad \alpha_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Seconde direction

$$\lambda_2 = 0.2, \quad \alpha_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix}$$

Niveau commun et contraste

Niveau commun : 90 %

$$Y_1 = \frac{Z_1 + Z_2}{\sqrt{2}}$$

Les deux notes contribuent dans le même sens.

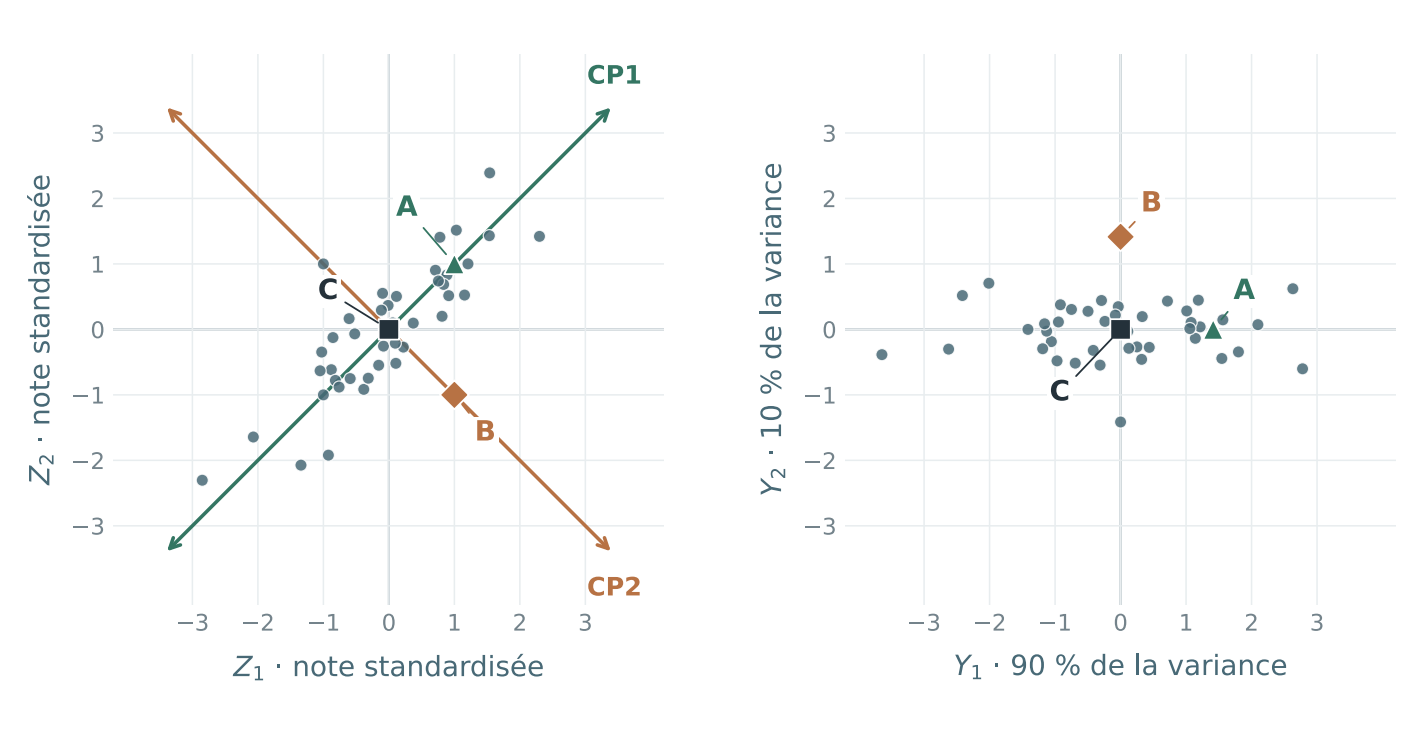
Contraste : 10 %

$$Y_2 = \frac{Z_1 - Z_2}{\sqrt{2}}$$

Un score positif indique une première note standardisée plus élevée.

Profil	z_1	z_2	y_1	y_2
A	1	1	$\sqrt{2}$	0
B	1	−1	0	$\sqrt{2}$
C	0	0	0	0

Un nouveau repère pour les mêmes étudiants



Les deux composantes conservent toutes les distances.

B et C se distinguent uniquement sur le second axe.

Réduire à une seule composante



La reconstruction vaut

$$\hat{z}_i = y_{i1}\alpha_1.$$

A reste au point $(1, 1)$.

B et **C** ont la même reconstruction : $(0, 0)$.

Pour B, l'erreur au carré vaut **2**, malgré les **90 %** conservés globalement.

Choisir le nombre de composantes

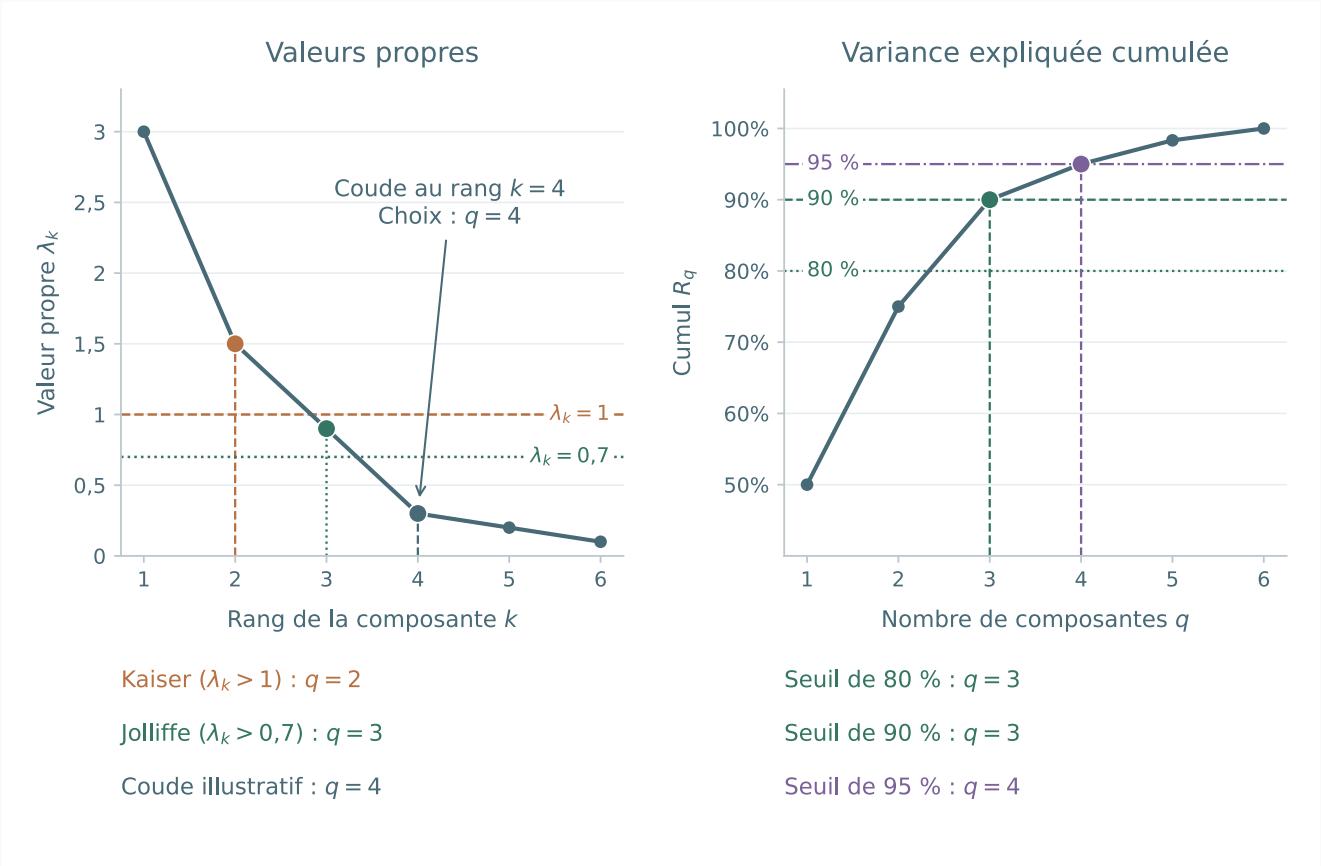
Un seuil de variance cumulée

Pour un seuil τ, choisir le plus petit q tel que $R_q \geq \tau$. Exemple d'une ACP centrée réduite de six variables :

Rang k	λ_k	Part r_k	Cumul R_k
1	3,0	50 %	50 %
2	1,5	25 %	75 %
3	0,9	15 %	90 %
4	0,3	5 %	95 %
5	0,2	3,3 %	98,3 %
6	0,1	1,7 %	100 %

Seuil de 80 % ou de 90 % : $q = 3$. Seuil de 95 % : $q = 4$.

Éboulis et variance cumulée



Dans cet exemple, le coude illustratif au rang 4 suggère $q = 4$. Sa position reste un jugement visuel à justifier.

Plusieurs règles, plusieurs choix possibles

Règle	Critère	q	R_q
Kaiser	$\lambda_k > 1$	2	75 %
Jolliffe	$\lambda_k > 0.7$	3	90 %
Variance cumulée	$R_q \geq 90\%$	3	90 %
Coude illustratif	Rupture au rang 4	4	95 %

- Les seuils de Kaiser et Jolliffe concernent l'ACP **centrée réduite**.
- Ces règles sont des repères heuristiques.
- Examiner le contenu des axes proches du seuil et l'objectif de l'analyse.

Composantes retenues et axes affichés

Trois composantes retenues

$R_3 = 90\%$ concerne l'espace formé par les trois premiers axes factoriels Y_1, Y_2 et Y_3.

Deux plans différents

(Y_1, Y_2) conserve 75 %.
(Y_1, Y_3) conserve 65 %.

Interpréter les plans factoriels

Lire la carte des individus

L'observation i a pour coordonnées (y_{i1}, y_{i2}) dans le premier plan factoriel.

- Donner un sens aux axes à partir des variables avant de décrire les profils.
- Utiliser la même échelle sur les deux axes pour lire les distances.
- Deux points proches peuvent différer sur les composantes omises.

Individu	y_1	y_2	y_3
D	0,1	0,1	3
E	0,1	0,1	−3

D et E se superposent dans le premier plan, mais leur distance vaut 6.

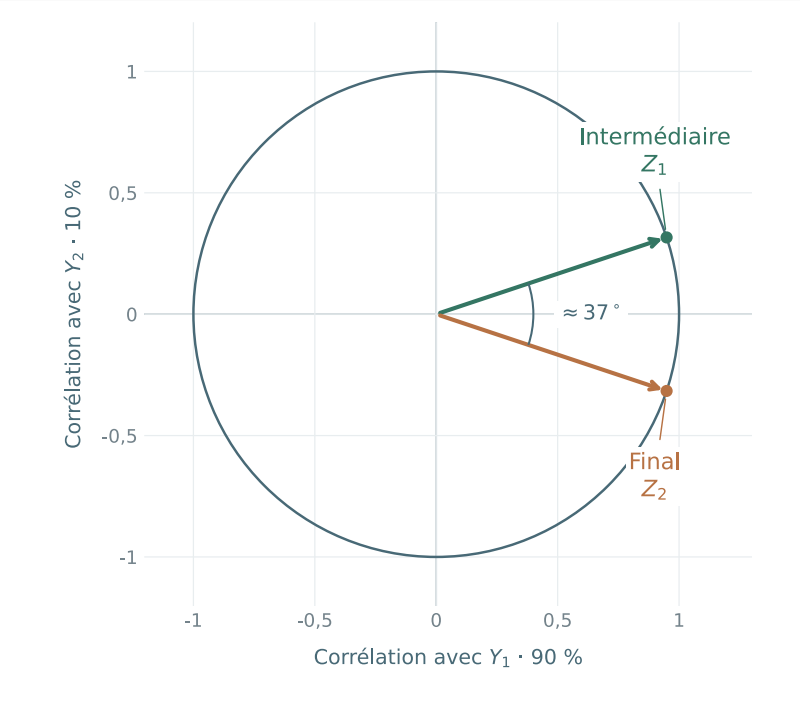
Coefficients, scores et corrélations

Quantité	Notation	Ce qu'elle décrit
Coefficient	α_{jk}	Poids de la variable j dans l'axe k
Score	y_{ik}	Position de l'observation i sur l'axe k
Corrélation	ρ_{jk}	Association entre la variable j et l'axe k

Dans une ACP centrée réduite, pour $\lambda_k > 0$:

$$\rho_{jk} = \operatorname{corr}(Z_j, Y_k) = \sqrt{\lambda_k}\alpha_{jk}.$$

Le cercle des corrélations des deux examens



$Z_1 : (0.949, 0.316)$

$Z_2 : (0.949, -0.316)$

Les deux notes augmentent avec le niveau commun Y_1.

Leurs corrélations avec Y_2 ont des signes opposés.

Les flèches atteignent le cercle car les deux axes représentent toute la variation. Le cosinus de leur angle vaut exactement 0,8.

Longueurs et angles des flèches

Longueur au carré

$\rho_{j1}^2 + \rho_{j2}^2 \leq 1$.
Cette somme mesure la part de variation de la variable restituée par le plan.

Angles, si les flèches sont longues

Angle petit : corrélation positive.
Près de 180° : négative.
Près de 90° : proche de zéro.

Contribution et qualité d'un individu

Contribution à l'axe

$$\mathrm{ctr}_{ik} = \frac{y_{ik}^2}{(n-1)\lambda_k}$$

Part de l'inertie de l'axe portée par l'individu.
Somme sur les individus : **1**.

Qualité sur l'axe

$$\cos_{ik}^2 = \frac{y_{ik}^2}{\|z_i\|^2}$$

Part de l'écart de l'individu au centre restituée par l'axe.
Somme sur les axes : **1**.

Contributions définies pour $\lambda_k > 0$; cosinus carrés définis pour $\|z_i\| > 0$. Dans un plan, additionner les cosinus carrés de ses axes.

Les profils A, B et C : deux lectures complémentaires

Dans le nuage de 45 étudiants : $\lambda_1 = 1.8$ et $\lambda_2 = 0.2$. La contribution moyenne d'un individu est $\frac{1}{45} \approx 2.22\%$.

Profil	**Contribution** à Y_1	**Contribution** à Y_2	**Qualité** sur Y_1	**Qualité** sur Y_2
A	2,53 %	0 %	100 %	0 %
B	0 %	22,73 %	0 %	100 %
C	0 %	0 %	Non définie	Non définie

Les observations A et B sont à la même distance du centre. L' observation B porte près du quart de l'inertie du second axe, qui est beaucoup plus faible.

Contribution et qualité d'une variable

Pour une ACP centrée réduite et $\lambda_k > 0$:

$$\mathrm{ctr}_{jk}^{\mathrm{var}} = \frac{\rho_{jk}^2}{\lambda_k} = \alpha_{jk}^2, \quad \text{qualité}_{jk} = \rho_{jk}^2$$

Indicateur	**Axe** Y_1	**Axe** Y_2
Contribution	50 %	50 %
Qualité de représentation	90 %	10 %

Sur un axe, les contributions des variables totalisent 1. Le repère $\frac{1}{p}$ est une contribution moyenne, pas un seuil de qualité.

Limites et restitution

Une réduction linéaire et un critère de variance

Un cercle

$(\cos(\theta), \sin(\theta))$ dépend d'un seul angle.
Pour une distribution uniforme sur le cercle, un axe conserve seulement **50 %** de la variance et confond des positions distinctes.

Une cible portée par un axe faible

Y_1 et Y_2 sont indépendantes, de variances 9 et 1.
Si la cible est $W = Y_2$, garder seulement Y_1 conserve **90 %** de la variance mais perd toute l'information sur la cible.

L'optimalité concerne la reconstruction quadratique par projection orthogonale. Elle ne garantit pas la pertinence pour chaque objectif.

Questions pour interpréter une ACP

1. Quelles variables et quelle préparation définissent la géométrie ?
2. Quelle variance le plan affiché conserve-t-il ?
3. Quelles variables donnent un sens aux axes ?
4. Quels individus et quelles variables contribuent le plus ?
5. Leurs cosinus carrés permettent-ils de commenter ce plan ?
6. Quels axes omis ou choix de préparation faut-il examiner ?

Les axes décrivent les données choisies. Ils ne démontrent ni une causalité, ni une classification validée.