Analyse exploratoire

STT-2200

Steven Golovkine

Automne 2026

Université Laval

Plan du cours

1 · Question

Objectif, population, unité et décision.

2 · Données

Qualité, provenance et représentation.

3 · Distance

Traduire ce que signifie « se ressembler ».

4 · Erreur

Mesurer et refléter la qualité et le coût des décisions.

5 · Validation

Estimer la performance sur de nouvelles observations.

De la question à la méthode

L’exploration prépare une décision

1 · Définir l’objectif → **2 · Collecter et préparer** → **3 · Élaborer et valider** → **4 · Mettre en œuvre** → **5 · Suivre et améliorer**

La partie visible

Le modèle peut parfois tenir en quelques lignes de code.

Mais le travail déterminant

Formats, unités, valeurs manquantes, doublons, catégories et documentation.

Une bonne question contraint l'analyse

Quatre éléments à préciser

- **Population** — à qui la conclusion s'applique-t-elle?
- **Unité** — que représente une ligne?
- **Cible** — quelle variable ou décision?
- **Résultat** — description, comparaison, prédiction ou segmentation?

Trop vague

« Analyser les données clients. »

Opérationnelle

« Peut-on prédire quels clients achèteront le nouveau produit d'épargne ? »

Une question précise limite les explorations sans direction et détermine le protocole d'évaluation.

Quatre choix structurent une méthode

Espace d'observation

Comment représenter chaque unité statistique ?

Distance ou similarité

Quelles différences doivent compter ?

Modèle ou algorithme

Quelle structure veut-on extraire ?

Erreur, coût ou perte

Comment reconnaître une bonne solution ?

Changer un seul objet peut changer le résultat et son interprétation.

Les données ne parlent jamais seules

Avant de modéliser

- Que mesure réellement chaque variable ?
- Qui manque dans l'échantillon ?
- Que signifie une absence ou un zéro ?
- Quelles contraintes y a-t-il ?

Après le déploiement du modèle

- Surveiller les entrées.
- Détecter la dérive des données.
- Réévaluer les hypothèses.
- Réentraîner ou revoir la question.

Exemple

Une absence d'achat peut traduire un manque d'intérêt, une rupture de stock, un problème d'accès ou une observation incomplète.

Représenter les données

Il est plus important d'avoir des données de qualité qu'un modèle sophistiqué

Population et structure

- représentativité;
- unité statistique;
- dépendance entre observations;
- déséquilibre des classes.

Valeurs et formats

- valeurs manquantes;
- doublons et incohérences;
- unités et échelles;
- valeurs extrêmes et modalités rares.

Un piège courant

Les codes `NA`, `N/A`, `?` et `Inconnu` peuvent représenter la même absence. Les conserver comme quatre catégories distinctes crée une structure artificielle.

La provenance des données leur donne du sens

D'où viennent-elles?

- systèmes internes;
- enquêtes;
- capteurs;
- expériences;
- dépôts publics;
- etc.

Que faut-il documenter?

- source, licence et date d'accès;
- population et échantillonnage;
- période et territoire;
- définition et unité des variables;
- filtres, exclusions et transformations;
- changements de collecte.

Une recommandation importante

Conserver les données brutes et produire la base analysée par transformations versionnées.

Une ligne = une unité et une colonne = une variable

Données *tidy*

- une variable par colonne;
- une observation par ligne;
- une seule valeur par cellule.

Le format de collecte

Il faut parfois pivoter le tableau de données, séparer une colonne en deux ou réunir plusieurs fichiers.

L'unité statistique

L'objet élémentaire sur lequel porte l'observation.

Elle fixe le niveau d'agrégation et dépend de la question, pas seulement du fichier.

Par exemple: individu, transaction, pays, image, pixel, document…

Le type d’une variable limite les opérations

Numérique

Ex: Revenu.

Nominale

Ex: Région.

Binaire

Ex: Fraude.

Ordinale

Ex: Satisfaction.

Coder n’est pas mesurer

Associer 1, 2 et 3 à des modalités conserve parfois un ordre, mais ne rend pas les écarts comparables.

Objets plus complexes

Texte, courbe, image et réseau demandent une représentation adaptée avant toute distance ou modélisation.

L'espace d'observation formalise les données

$$\mathcal{X} = \mathcal{X}_1 \times \mathcal{X}_2 \times \ldots \times \mathcal{X}_p$$

Variables numériques

Ex: $\mathcal{X} = \mathbb{R}^p$

Données mixtes

Ex: $\mathbb{R}_+^3 \times \mathcal{R} \times \mathcal{S}$

Objets structurés

Ex: Courbe dans $\mathcal{C}([a, b])$

La représentation choisie détermine les distances et les modèles possibles.

Pause code

Mesurer les ressemblances

Une distance formalise la notion de « proche »

Quatre propriétés

Pour tous $x, y, z \in \mathcal{X}$:

1. $d(x, y) \geq 0$
2. $d(x, y) = 0 \Leftrightarrow x = y$
3. $d(x, y) = d(y, x)$
4. $d(x, y) \leq d(x, z) + d(z, y)$

Distance

Plus elle augmente, plus les observations sont dissemblables.

Similarité

Plus elle augmente, plus les observations se ressemblent.

$$s(x, y) = \frac{1}{1+d(x,y)}$$

Les unités changent la géométrie

Minkowski

$$d_q(x, y) = \left(\sum_{j=1}^{p} |x_j - y_j|^q \right)^{\frac{1}{q}}$$

$q = 1$: Distance de Manhattan

$q = 2$: Distance euclidienne

Standardisation

$$z_j(x) = \frac{x_j - \mu_j}{\sigma_j}$$

Chaque différence est mesurée en nombre d'écarts-types.

Exemple

Dans une observation « âge, revenu, achats », le revenu exprimé en dollars domine souvent la distance brute. Standardiser change les voisins jugés les plus proches.

Distance de Hamming

Hamming

$$d_H(x, y) = \sum_{j=1}^{p} 1(x_j \neq y_j)$$

Compte tous les désaccords entre variables qualitatives.

Exemple

x_j	1	0	1	0	0
y_j	1	0	0	1	0
$1(x_j \neq y_j)$	0	0	1	1	0

$$d_H(x, y) = 0 + 0 + 1 + 1 + 0 = 2$$

Indice de Jaccard

	$y_j = 1$	$y_j = 0$
$x_j = 1$	M_{11} Présence commune	M_{10} Présent dans x seulement
$x_j = 0$	M_{01} Présent dans y seulement	M_{00} Absence commune

M_{ab} compte les positions où $x_j = a$ et $y_j = b$.

$$J = \frac{M_{11}}{M_{11}+M_{10}+M_{01}} \quad \text{et} \quad d_J = 1 - J$$

Exemple

$$x = (1,0,1,0,0)^\top, \quad y = (1,0,0,1,0)^\top$$

$$M_{11} = 1, \quad M_{10} = 1, \quad M_{01} = 1, \quad M_{00} = 2$$

$$J = \tfrac{1}{3} \quad \text{et} \quad d_J = \tfrac{2}{3}$$

Choisir une distance, c’est choisir une manière de comparer

Quantitative

Euclidienne standardisée si les dimensions doivent peser de façon comparable.

Qualitative

Jaccard si les achats communs comptent davantage que les absences communes.

Données mixtes

Combiner distances numériques, qualitatives ou autres avec des poids justifiés.

Question à se poser

Deux observations proches doivent-elles partager des valeurs, des catégories, une trajectoire, des voisins ou une conséquence pratique?

Pause code

Mesurer l’erreur

Erreur, coût et perte désignent la même idée

$$Y = f(X) + \varepsilon$$

Information systématique

$f(X)$ représente ce que les variables explicatives apportent sur la réponse.

Part non expliquée

ε regroupe bruit, variables absentes et variabilité naturelle.

Une fonction d'erreur, de coût ou de perte quantifie la qualité d'une décision.

MSE et MAE ne pénalisent pas les mêmes erreurs

Erreur quadratique moyenne

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Les grandes erreurs pèsent fortement.

Erreur absolue moyenne

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

L'erreur typique est plus robuste aux valeurs extrêmes.

Choisir la MSE

Quand les erreurs extrêmes ont des conséquences disproportionnées.

Choisir la MAE

Quand l'écart absolu habituel correspond mieux à l'usage.

Taux d'erreur en classification

$$\mathrm{ER} = \frac{1}{n}\sum_{i=1}^{n} 1(y_i \neq \hat{y}_i)$$

Compter les erreurs

L'indicatrice vaut 1 lorsque la classe prédite diffère de la classe observée, et 0 sinon. La somme compte les erreurs.

Exemple

Avec 3 erreurs sur 20 observations,

$$\mathrm{ER} = \frac{3}{20} = 15\%.$$

L'exactitude vaut alors $1 - \mathrm{ER} = 85\%$.

Attention, le taux global ne distingue pas les faux positifs des faux négatifs et peut donc masquer la qualité d'une décision sur une classe rare.

La matrice de confusion compte quatre décisions

	Prédit positif	Prédit négatif
Réel positif	Vrai positif (VP)	Faux négatif (FN)
Réel négatif	Faux positif (FP)	Vrai négatif (VN)

Cas manqués

Les faux négatifs sont positifs en réalité, mais non détectés.

Fausses alertes

Les faux positifs sont négatifs en réalité, mais signalés à tort.

Quatre mesures répondent à quatre questions

Sensibilité

$$\frac{\text{VP}}{\text{VP} + \text{FN}}$$

Parmi les positifs, combien sont détectés?

Spécificité

$$\frac{\text{VN}}{\text{VN} + \text{FP}}$$

Parmi les négatifs, combien sont écartés?

Précision ou rappel

$$\frac{\text{VP}}{\text{VP} + \text{FP}}$$

Parmi les alertes, combien sont réellement positives?

Abaisser le seuil augmente généralement la sensibilité mais réduit la spécificité. La précision dépend aussi de la fréquence de la classe positive.

Une exactitude élevée peut masquer l'échec

1 000 transactions

- 20 fraudes;
- 16 détectées;
- 4 manquées;
- 30 fausses alertes.

$$\text{Sensibilité} = \text{Rappel} = \frac{16}{20} = 80\%$$

$$\text{Spécificité} = \frac{950}{980} \approx 96,9\%$$

$$\text{Précision} = \frac{16}{46} \approx 34,8\%$$

Une bonne spécificité peut coexister avec beaucoup de fausses alertes.

Le coût réel doit guider le critère

Dépistage

Manquer une maladie peut coûter davantage qu'un examen complémentaire.

Fraude

Le coût dépend du montant, de la vérification et de la relation client.

Stocks

Rupture, stockage et gaspillage rendent les erreurs asymétriques.

Conséquence

Le seuil de décision et la mesure de performance doivent refléter les conséquences pratiques, pas seulement le nombre d'erreurs.

Pause code

Biais, variance et bruit décomposent l'erreur

$$\mathbb{E}\Big(\big(Y_0 - \hat{f}(x_0)\big)^2\Big) = \text{Biais}\big(\hat{f}(x_0)\big)^2 + \text{Var}\big(\hat{f}(x_0)\big) + \sigma^2$$

Biais²

Écart systématique entre la prédiction et la relation réelle.

Variance

Sensibilité de la prédiction au choix du jeu d'entraînement.

Bruit σ^2

Variabilité irréductible avec les variables disponibles.

Le biais statistique n'est ni un biais de collecte ni un biais social.

La flexibilité crée un compromis

Sous-ajustement

Biais élevé

Variance faible

→

Compromis utile

Structure captée

Stabilité suffisante

←

Sur-ajustement

Biais faible

Variance élevée

Entraînement

L'erreur diminue généralement avec la flexibilité.

Nouvelles données

L'erreur diminue, atteint un minimum, puis remonte souvent.

Pause code

Valider pour généraliser

Trois ensembles, trois rôles

Entraînement

Estimer les paramètres et les transformations.

Validation

Comparer les méthodes, régler les hyperparamètres et le seuil.

Test

Estimer une seule fois la performance finale.

Si le résultat du test modifie le modèle, le test est devenu une validation.

La séparation doit imiter l'usage futur

Aléatoire

Observations indépendantes issues de la même population.

Stratifiée

Proportions des classes préservées dans chaque ensemble.

Par groupe

Toutes les visites d'un patient restent ensemble.

Temporelle

Le passé entraîne et une période ultérieure valide et teste.

Les proportions 60-20-20 ou 70-15-15 sont des points de départ. Les effectifs utiles, la rareté des classes et le nombre de groupes comptent davantage.

Une fuite rend l'évaluation trop optimiste

Procédure incorrecte

Imputer, standardiser ou sélectionner sur toute la base.

Procédure correcte

Ajuster la transformation sur l'entraînement, puis l'appliquer sur les autres ensembles.

Autres fuites

Une date future, une observation du même individu ou une variable construite après l'événement à prédire peuvent transmettre de l'information interdite.

Toute transformation apprise fait partie du modèle.

Pause code

La validation croisée réduit la dépendance à un seul découpage

Tour	Pli 1	Pli 2	Pli 3	Pli 4	Pli 5
1	V	E	E	E	E
2	E	V	E	E	E
3	E	E	V	E	E
4	E	E	E	V	E
5	E	E	E	E	V

E · Entraînement

Ajuster toute la procédure sur quatre plis.

V · Validation

Prédire sur le pli restant, et calculer son erreur.

Les prédictions hors pli proviennent toujours d'un modèle qui n'a pas vu l'observation correspondante.

L’erreur globale pondère les plis

$$\mathrm{Err}_k = \frac{1}{n_k} \sum_{i \in I_k} L\big(y_i, \hat{f}^{-k}(x_i)\big)$$

$$\widehat{\mathrm{Err}}_{\mathrm{CV}} = \sum_{k=1}^{K} \frac{n_k}{n} \mathrm{Err}_k$$

Exemple à cinq plis égaux

Erreurs: 18 %, 22 %, 20 %, 16 % et 24 %.

Moyenne: $(18\% + 22\% + 20\% + 16\% + 24\%)/5 = 20\%$.

L’étendue de 16 % à 24 % révèle aussi une sensibilité au découpage.

Le choix du nombre de plis K est un compromis

K	Atout	Limite
5	Calcul plus rapide	Chaque modèle utilise 80 % des données
10	Bon compromis général	Deux fois plus d'ajustements
n	Entraînement sur $n-1$ cas	Coûteux; erreurs très corrélées

Choix courant

$K = 5$ ou $K = 10$ convient à de nombreux problèmes indépendants.

Répéter

Plusieurs partitions réduisent la dépendance à une seule graine aléatoire.

Une bonne moyenne ne suffit pas

Rapporter

- moyenne des erreurs;
- dispersion entre les plis;
- effectifs et classes;
- règle de séparation.

Vérifier

- même contexte futur;
- ordre temporel respecté;
- groupes non séparés;
- transformations sans fuite.

Interprétation

Les erreurs des plis ne sont pas indépendantes puisque leurs entraînements se chevauchent. Leur dispersion décrit une stabilité observée, pas automatiquement un intervalle de confiance valide.

Pause code

Une analyse défendable relie tous les choix

Question

Population et usage.

→

Données

Unité et qualité.

→

Méthode

Espace et distance.

→

Décision

Erreur et validation.

Une performance n'a de sens qu'à l'intérieur d'un protocole explicite.