Les k-moyennes

STT-2200

Steven Golovkine

Automne 2026

Université Laval

Le critère des k-moyennes

Les notations

Notation	Rôle
$x_i \in \mathbb{R}^p$	Observation numérique, après les transformations choisies
k	Nombre de groupes, fixé pour un ajustement
$C_1, \ldots, C_k$	Partition des indices des n observations
$\mu_1, \ldots, \mu_k$	Centres ou centroïdes dans le même espace que les données
$n_g = \lvert C_g \rvert$	Effectif du groupe g

On ajuste les groupes et les centres sans variable réponse.

Une somme de distances au carré

$$Q(\mathcal{C}, \mu_1, ..., \mu_k) = \sum_{g=1}^{k} \sum_{i \in C_g} \|x_i - \mu_g\|^2$$

Affectations inconnues

Pour chaque observation, choisir le centre qui la représente.

Centres inconnus

Placer chaque centre de façon à limiter les écarts dans son groupe.

Les k-moyennes cherchent à minimiser Q sur ces deux ensembles.

Pourquoi le centroïde est une moyenne

Pour un groupe non vide C_g fixé, notons $\overline{x}_g$ sa moyenne.

$$\sum_{i \in C_g} \|x_i - m\|^2 = \sum_{i \in C_g} \|x_i - \overline{x}_g\|^2 + n_g \|m - \overline{x}_g\|^2$$

Preuve. Écrire $x_i - m = (x_i - \overline{x}_g) + (\overline{x}_g - m)$. Le terme croisé s'annule car

$$\sum_{i \in C_g} (x_i - \overline{x}_g) = 0.$$

Le dernier terme est positif ou nul. Il s'annule exactement pour $m = \overline{x}_g$. □

À groupes fixés, la moyenne minimise la somme des distances euclidiennes au carré.

Inertie et choix de la distance

$$\mu_g = \overline{x}_g \quad \Rightarrow \quad Q = W(\mathcal{C}) = \sum_{g=1}^{k} \sum_{i \in C_g} \left\| x_i - \overline{x}_g \right\|^2$$

Lien avec l'introduction

$T = W + B$ dans l'espace euclidien choisi.
À données fixées, minimiser W revient à maximiser B.

Une moyenne adaptée au critère

Le centroïde peut être absent du jeu de données.
Avec une autre dissimilarité, la moyenne n'est plus nécessairement le meilleur centre.

L’algorithme de Lloyd

Initialiser les centres

Un nombre de groupes fixé

Choisir k pour cet ajustement.
Initialiser $\mu_1^{(0)}, \ldots, \mu_k^{(0)}$, par exemple avec k observations distinctes tirées au hasard.

Deux étapes à répéter

Affecter chaque observation au centre le plus proche.
Recalculer les moyennes des groupes obtenus.

L'algorithme de Lloyd alterne deux minimisations simples, chacune conditionnelle à l'autre.

L'initialisation par des observations exige au moins k observations distinctes.

Étape d'affectation

$$c_i^{(t+1)} = \underset{g \in \{1,\ldots,k\}}{\operatorname{argmin}} \left\| x_i - \mu_g^{(t)} \right\|^2$$

$$C_g^{(t+1)} = \left\{ i : c_i^{(t+1)} = g \right\}$$

Centres inchangés

Chaque observation choisit le centre qui minimise sa propre contribution à Q.

Égalité de distance

Appliquer une règle de départage fixée, par exemple choisir le premier centre.

Étape de mise à jour

$$\mu_g^{(t+1)} = \frac{1}{n_g^{(t+1)}} \sum_{i \in C_g^{(t+1)}} x_i, \quad \text{et} \quad n_g^{(t+1)} = \left| C_g^{(t+1)} \right|$$

Groupes inchangés

Remplacer chaque centre par la moyenne de son groupe.
Cette mise à jour minimise Q pour les affectations courantes.

Groupe vide

Si $n_g^{(t+1)} = 0$, la moyenne n'existe pas.
L'implémentation doit prévoir une stratégie, comme réinitialiser ce centre.

Décroissance et arrêt de l'algorithme

$$Q_{t+1} \leq Q_t, \quad \text{et} \quad Q_t \geq 0$$

Une amélioration à chaque étape

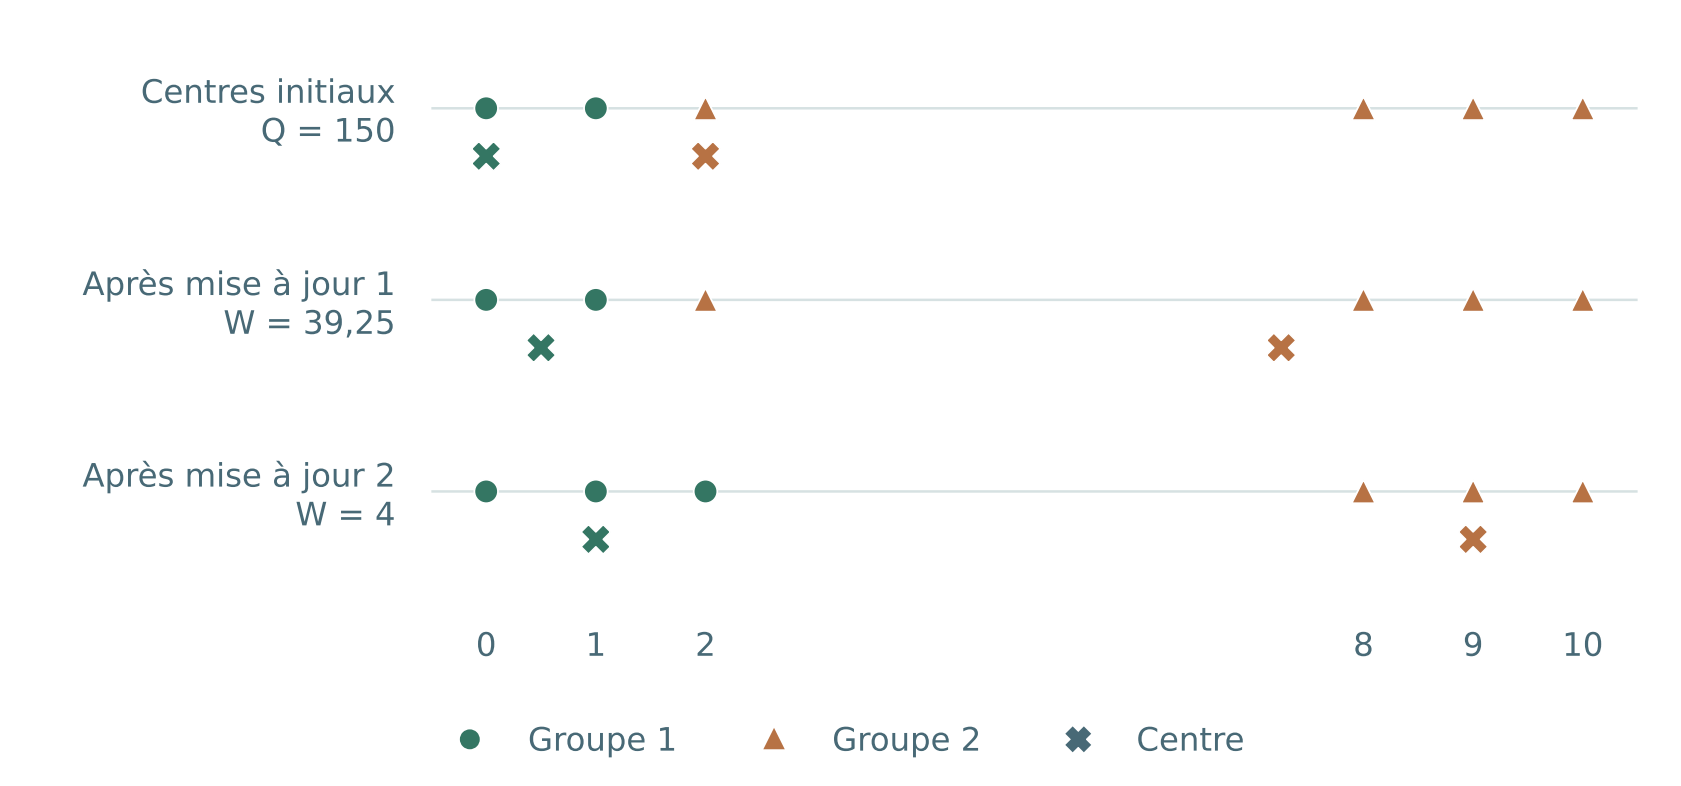
L'affectation puis la mise à jour n'augmentent pas le critère.
Une étape peut laisser sa valeur inchangée.

Un arrêt à contrôler

Affectations stabilisées ou règle d'arrêt numérique.
Un nombre maximal d'itérations évite une exécution indéfinie.

En arithmétique exacte, avec des groupes non vides et un départage cohérent, l'algorithme de Lloyd se stabilise. Le minimum global n'est cependant pas garanti.

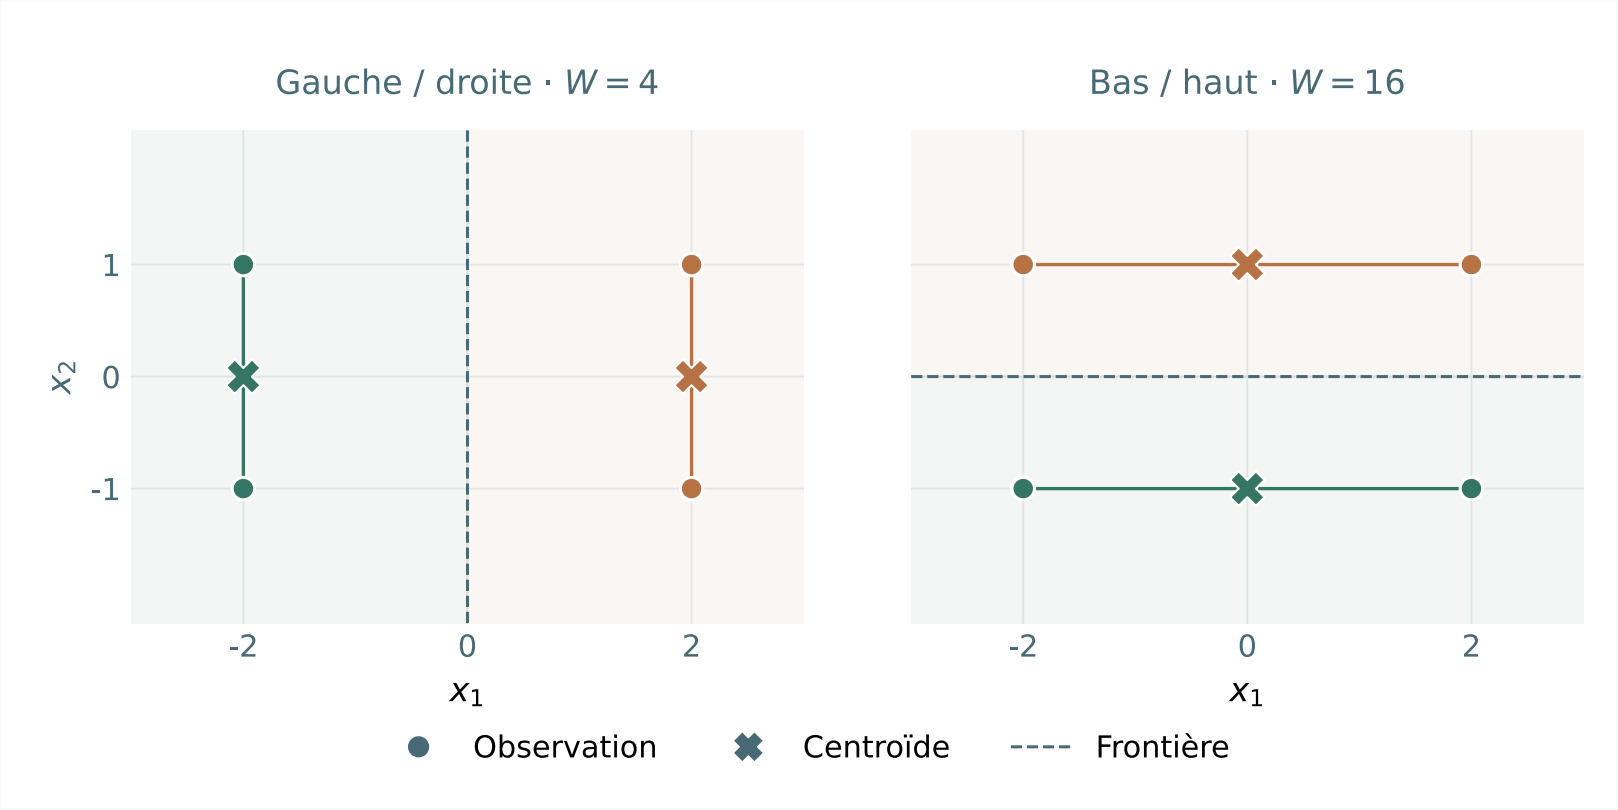
Exemple



Les croix indiquent les centres, décalés sous les observations pour la lecture. Après la première mise à jour, la réaffectation de 2 reste à effectuer.

Initialisation et géométrie

Deux solutions stables pour les mêmes données



Dans les deux partitions, chaque centre est la moyenne de son groupe et chaque point rejoint son centre le plus proche.

Plusieurs départs et davantage d'itérations

Plusieurs initialisations

Explorer plusieurs solutions pour le même k.
Retenir celle de plus faible inertie W parmi les ajustements réalisés.

Plus d'itérations par départ

Laisser chaque ajustement atteindre son critère d'arrêt.
Prolonger un point fixe ne permet pas de quitter cette solution.

Une graine fixe rend le calcul reproductible, sans améliorer la partition.

Affecter une nouvelle observation

Appliquer les transformations déjà estimées, puis utiliser les centres fixés.

$$\hat{c}(x) = \underset{g \in \{1,\dots,k\}}{\operatorname{argmin}} \left\| x - \mu_g \right\|^2$$

Exemple : $x = 6$

Avec les centres 1 et 9 :

$$(6-1)^2 = 25, \quad (6-9)^2 = 9$$

Affectation au groupe 2.

Un modèle inchangé

Les centres ne bougent pas.
Inclure ce point dans un nouvel ajustement peut déplacer les centres et changer d'anciennes affectations.

La proximité à un centre ne fournit pas, à elle seule, une probabilité d'appartenance.

Choisir le nombre de groupes

Pourquoi l'inertie seule ne choisit pas k

Notons W_k^* la plus faible inertie possible avec k groupes.

$$W_{k+1}^* \leq W_k^*$$

Argument de découpage

Scinder un groupe conserve ou réduit la somme des carrés.
Avec un groupe par observation, l'inertie vaut zéro.

Résultats d'un algorithme local

Les ajustements calculés n'atteignent pas toujours W_k^*.
Une remontée de l'inertie peut signaler un mauvais départ ou un problème de convergence.

Pour chaque valeur candidate de k, comparer plusieurs initialisations.

Le coude et les critères complémentaires

Courbe des inerties

Rechercher une rupture après laquelle un groupe supplémentaire apporte peu de réduction de W.

Plusieurs coudes, ou aucun coude net, sont possibles.

Séparation et interprétation

Comparer silhouette moyenne et Calinski-Harabasz.

Examiner les effectifs, les profils et la stabilité.

Les critères peuvent proposer des choix différents.

Le choix de k doit répondre à la question de l'analyse.

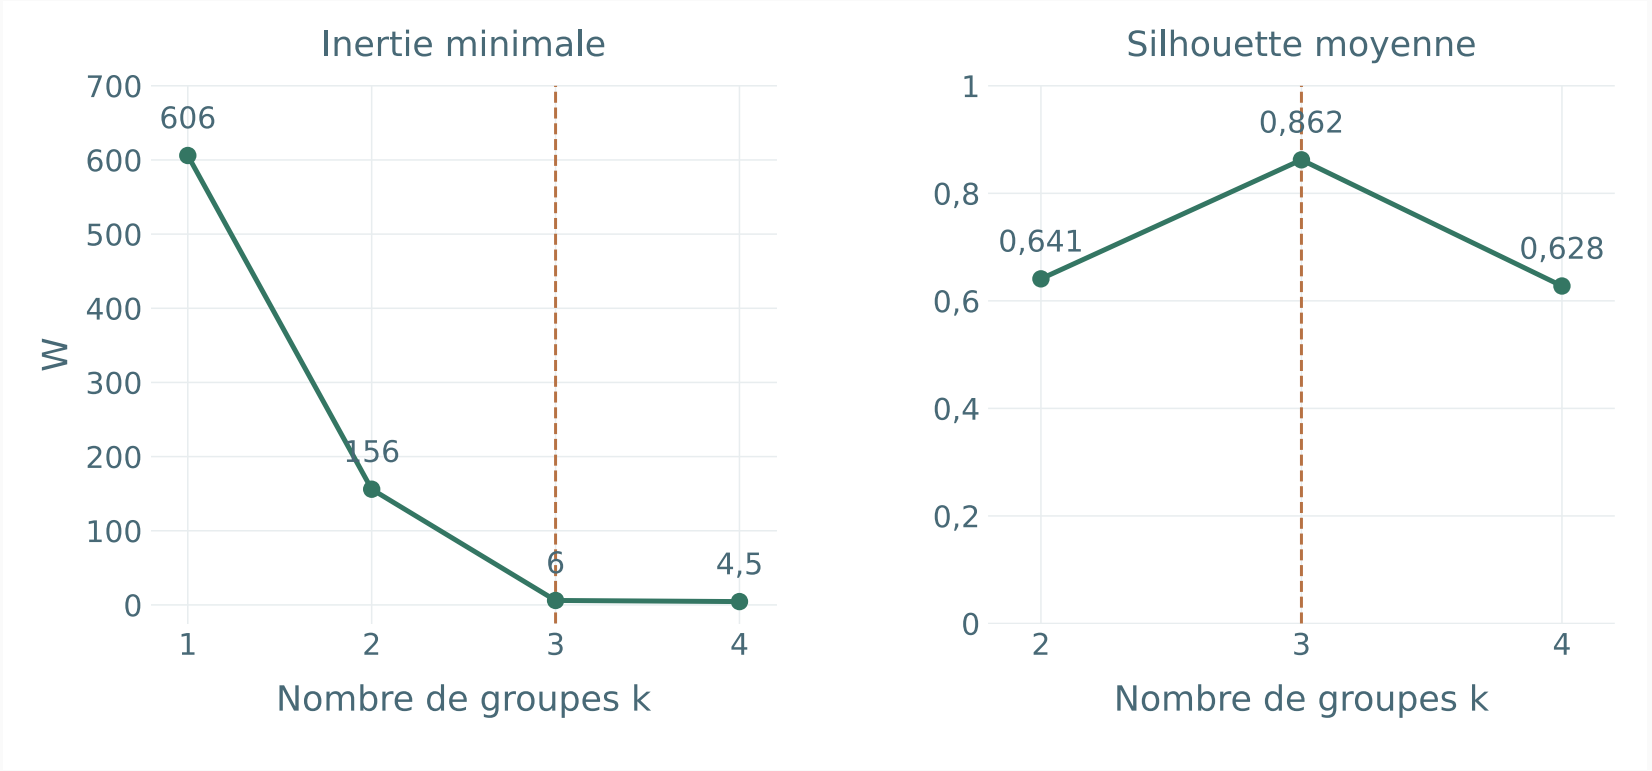
Exemple : neuf observations sur une droite

$$0, 1, 2, 10, 11, 12, 20, 21, 22, \quad \overline{x} = 11, \quad T = 606$$

k	Groupes retenus, écrits en termes de valeurs
1	Toutes les observations
2	$\{0, 1, 2\}$ et $\{10, 11, 12, 20, 21, 22\}$
3	$\{0, 1, 2\}$, $\{10, 11, 12\}$ et $\{20, 21, 22\}$
4	$\{0\}$, $\{1, 2\}$, $\{10, 11, 12\}$ et $\{20, 21, 22\}$

Ici, les minima d'inertie se vérifient par toutes les découpes consécutives des valeurs ordonnées. Plusieurs partitions sont optimales pour $k = 2$ et $k = 4$.

Exemple : un coude à trois groupes



Les gains successifs d'inertie sont 450, 150 puis seulement 1,5.

Limites et précautions

Des formes que les centres résument mal

Dispersions et effectifs différents

L'algorithme peut couper un groupe très étendu ou fusionner de petits groupes voisins.
L'égalité des tailles ou des covariances n'est pas une contrainte formelle.

Deux anneaux concentriques

Avec $k = 2$, la frontière entre les centres est une droite.
Elle ne peut séparer un anneau intérieur d'un anneau extérieur.

Selon la géométrie recherchée, envisager une autre représentation, une méthode par densité ou une méthode spectrale.

Valeurs extrêmes et séparation peu nette

Une forte sensibilité aux extrêmes

Les distances au carré et les moyennes amplifient leur influence.
Une observation peut déplacer un centre ou former un groupe isolé.
L'écart-type est lui aussi sensible aux extrêmes.

Une affectation pour chaque point

Les k-moyennes découpent aussi un nuage continu.
Les observations isolées ou proches d'une frontière reçoivent un groupe.
Les distances ne sont pas des probabilités d'appartenance.

Examiner les observations atypiques et leur effet, sans les supprimer automatiquement.

Les vérifications d'une analyse

Espace choisi

Variables, valeurs manquantes, unités et transformations documentées.

Ajustements

Plusieurs départs, convergence contrôlée et comparaison des inerties.

Nombre de groupes

Critères, effectifs et profils confrontés à la question de départ.

Stabilité

Sensibilité aux initialisations et aux variations des données examinée séparément.