La méthode des k plus proches voisins

STT-2200

Steven Golovkine

Automne 2026

Université Laval

Prédire par voisinage

Une réponse connue pendant l'apprentissage

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}, \quad x_i \text{ un vecteur de } p \text{ variables explicatives}, \quad \hat{y} = \hat{f}(x)$$

Classification

Prédire une **catégorie**.
Exemple : l'espèce d'un manchot à partir de ses quatre mesures corporelles.

Régression

Prédire une **quantité**.
Exemple : la masse d'un manchot à partir des trois autres mesures corporelles.

Les variables explicatives doivent être disponibles au moment de prédire.

↳ x

Les notations

Symbole	Signification
n	Nombre d'observations d'entraînement
p	Nombre de variables explicatives
K	Nombre de classes, en classification
k	Nombre de voisins retenus, avec $1 \leq k \leq n$
$d(x, x_i)$	Distance entre une nouvelle observation et l'observation i
$\mathcal{N}_k(x)$	Indices des k voisins d'entraînement retenus pour x

Le nombre de voisins k et le nombre de classes K sont distincts.

L'algorithme des k-NN

1 · Préparer

Les variables, avec les paramètres appris sur l'entraînement.

→ standardisation

2 · Calculer les distances

De la nouvelle observation à chaque exemple connu.

3 · Retenir les voisins

Les k plus proches, avec une règle d'égalité fixée à l'avance.

4 · Combiner les réponses

Vote en classification, moyenne en régression.

La recherche des voisins utilise les variables explicatives. La réponse de la nouvelle observation reste inconnue.

Une méthode locale et non paramétrique

Ce que la méthode conserve

Les observations d'entraînement et leurs réponses.
Le voisinage change selon le point à prédire.

Ce qu'il faut choisir

Les variables, leur préparation, la distance, k et les poids.
L'hypothèse utile : la proximité doit informer sur la réponse.

« Non paramétrique » : aucune équation globale avec un nombre fixé de coefficients. Les choix de méthode restent essentiels.

Classification et régression

Le vote des voisins

$$\hat{\eta}_g(x) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(x)} \mathbf{1}\{y_i = g\}, \quad \text{où} \quad g = 1, \ldots, K$$

$$\hat{g}(x) = \underset{g \in \{1,\ldots,K\}}{\operatorname{argmax}} \, \hat{\eta}_g(x)$$

- Chaque voisin apporte une voix.
- L'indicatrice vaut 1 pour un voisin de classe g, et 0 sinon.
- La classe ayant le plus de voix gagne, selon la règle de départage.

Avec plusieurs classes, gagner ne demande pas forcément plus de 50 % des voix. Une proportion locale n'est pas une garantie de probabilité bien calibrée.

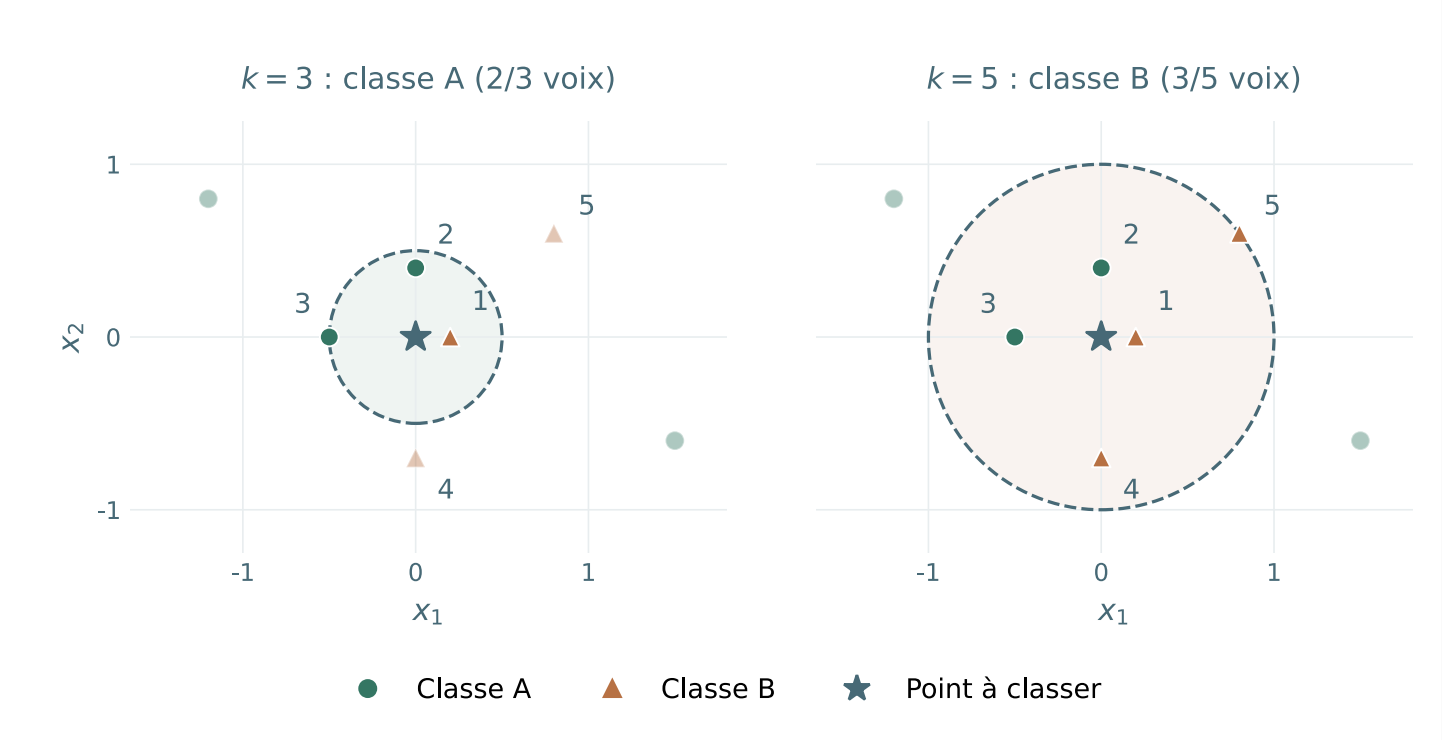
Exemple : cinq voisins du point origine

On cherche la classe de $x = (0, 0)^\top$, avec la distance euclidienne.

Rang	Coordonnées	Distance	Classe
1	$(0.2, 0)$	0,2	B
2	$(0, 0.4)$	0,4	A
3	$(-0.5, 0)$	0,5	A
4	$(0, -0.7)$	0,7	B
5	$(0.8, 0.6)$	1,0	B

$k = 1$: B. $k = 3$: A, avec 2 voix sur 3. $k = 5$: B, avec 3 voix sur 5.

Deux voisinages, deux décisions



Le cercle passe par le k-ième voisin. Les numéros renvoient au tableau. Les deux points les plus éloignés sont hors des cinq voisins du tableau.

Deux sortes d'égalités

Égalité de distances

Plusieurs points sont à la distance du k-ième voisin.

Pour en garder exactement k, on peut utiliser un ordre stable des lignes.

Égalité de voix

Plusieurs classes ont le même nombre maximal de voix.

On peut retenir la classe du premier voisin parmi les classes ex aequo.

Un k impair évite l'égalité pour deux classes et un vote uniforme. Avec trois classes, 5 voix peuvent se répartir en 2, 2 et 1.

Ces règles font partie de la méthode et précèdent son évaluation.

La moyenne des voisins en régression

$$\hat{f}_k(x) = \frac{1}{k} \sum_{i \in \mathcal{N}_k(x)} y_i$$

Pour trois réponses 10, 12 et 14 :

$$\hat{f}_3(x) = \frac{10 + 12 + 14}{3} = 12.$$

La moyenne minimise la somme des erreurs **quadratiques** des voisins :

$$\hat{f}_k(x) = \operatorname*{argmin}_a \sum_{i \in \mathcal{N}_k(x)} (y_i - a)^2.$$

Une médiane minimise plutôt la somme des erreurs absolues et résiste davantage aux réponses extrêmes.

Donner davantage de poids aux voisins proches

$$\hat{f}_k(x) = \frac{\sum_{i \in \mathcal{N}_k(x)} w_i(x) y_i}{\sum_{i \in \mathcal{N}_k(x)} w_i(x)}$$

moyenne pondérée par w_i

On impose $w_i(x) \geq 0$ et une somme des poids strictement positive. Un choix possible, si $d(x, x_i) > 0$, est $w_i(x) = d(x, x_i)^{-1}$.

Voisin	Distance	Réponse
1	1	10
2	3	14

Moyenne uniforme : 12. Moyenne pondérée : $\frac{10+\frac{14}{3}}{1+\frac{1}{3}} = 11$.

Choix de k

Le compromis biais-variance

Petit k

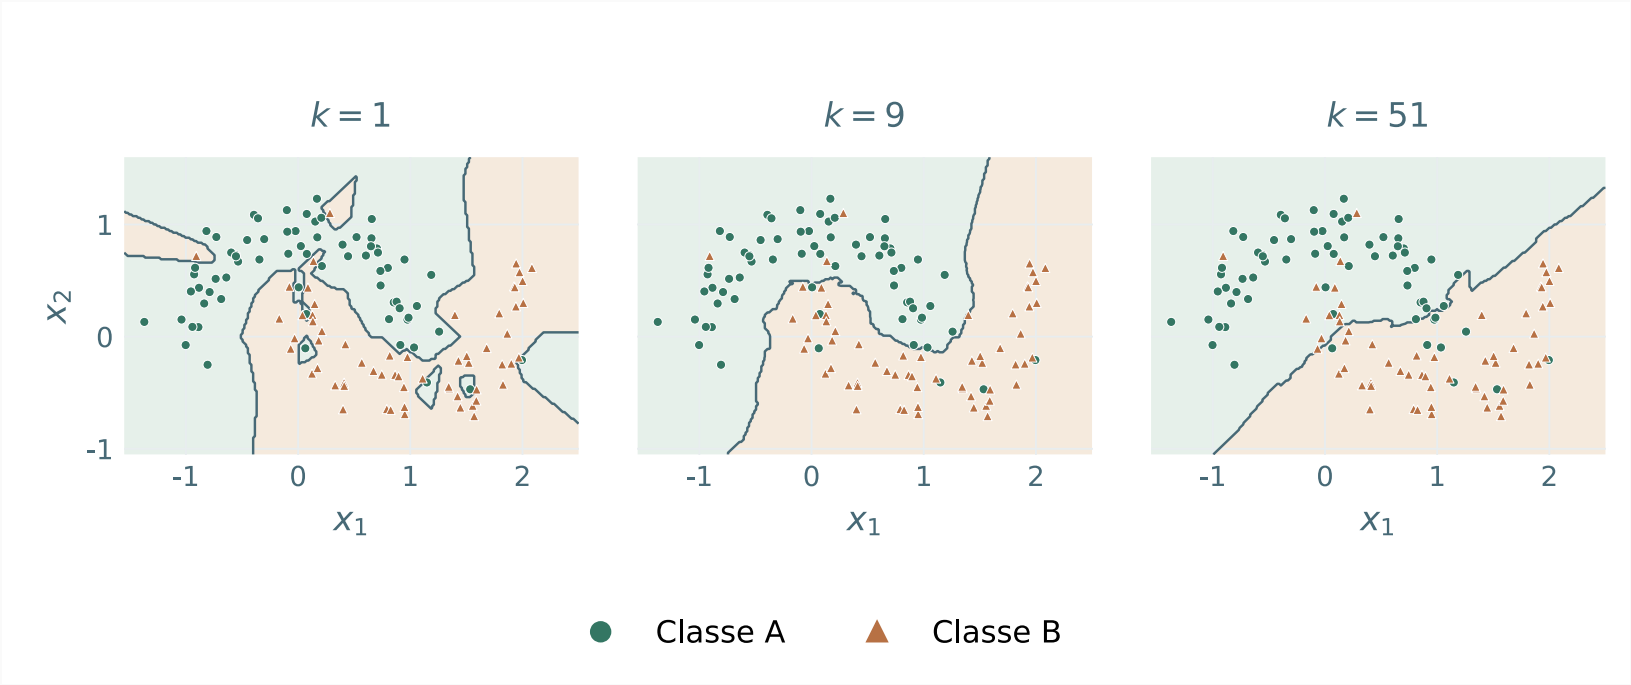
Prédiction très locale, capable de suivre des détails fins.
Plus sensible au bruit, aux étiquettes erronées et aux observations atypiques.

Grand k

Prédiction généralement plus stable.
Risque de mélanger des régions différentes et d'effacer une structure utile.

À $k = n$, avec des poids uniformes : classe la plus fréquente en classification (hors égalité), et moyenne globale en régression.

L’effet de k sur les régions de décision



Même échantillon simulé, avec quelques étiquettes bruitées. L’apparence de la frontière sur l’entraînement ne suffit pas à choisir k.

Pourquoi l'erreur d'entraînement peut tromper

Supposons $k = 1$ et des vecteurs explicatifs d'entraînement tous distincts.

- Chaque observation est son propre plus proche voisin, à distance nulle.
- Sa prédiction recopie donc sa réponse, même si celle-ci contient du bruit.
- L'erreur sur l'entraînement vaut zéro.

Pour évaluer la généralisation, l'observation évaluée doit être absente de l'ensemble dans lequel on cherche ses voisins.

Le choix de k par validation croisée

On compare, par exemple, $k \in \{1, 3, 5, 7, 9, 15, 21, 31\}$ sur les mêmes plis.

1 · Partager

Réserver un test final, puis diviser l'entraînement en plis.

2 · Préparer

Pour chaque pli, apprendre la préparation des données sur les autres plis.

3 · Prédire

Prédire le pli réservé pour chaque valeur candidate de k.

4 · Comparer

Comparer les erreurs de validation et appliquer le départage prévu.

Chaque k doit être au plus égal à l'effectif d'entraînement dans chaque pli. Aucune valeur n'est universellement optimale.

La procédure complète reste dans les plis

Étape	Partie entraînement	Partie validation
Préparation	Estimer centrage, réduction, imputation…	Appliquer ces paramètres
Variables ou ACP	Apprendre la sélection ou les axes	Appliquer la transformation
k-NN	Conserver les exemples préparés	Chercher les voisins et prédire
Évaluation	Aucun usage des réponses de validation	Comparer prédictions et réponses

Après les choix : réapprendre sur tout l'entraînement, puis évaluer le test une fois. Le test ne choisit ni k, ni la distance, ni les poids.

Forces et limites

Une règle flexible et interprétable localement

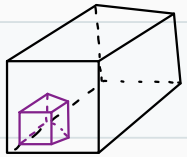
- Aucune relation linéaire ni distribution normale des classes n'est imposée.
- Les régions de décision peuvent suivre des formes irrégulières.
- Les voisins permettent d'examiner les exemples à l'origine d'une prédiction.

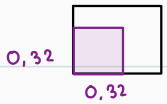
L'explication par les voisins reste pertinente seulement si les variables et la distance représentent une similarité utile pour la tâche.

La difficulté des grandes dimensions

Illustration : des données uniformes dans un cube unité de dimension p. Un sous-cube de côté h occupe une fraction h^p du volume.

$$h^p = 0.1 \quad \Rightarrow \quad h = 0.1^{\frac{1}{p}}$$



Dimension p	Volume couvert	Côté h
2	10 % 	0,32
10	10 %	0,79
50	10 %	0,95

Pour couvrir la même fraction du volume, le voisinage s'étend sur une grande partie de chaque coordonnée.

Classes rares et régions peu observées

Une classe rare

Un grand voisinage peut être dominé par la classe fréquente.
Une petite région utile peut disparaître dans le vote.

Un point éloigné

Les k-NN renvoient une prédiction même quand tous les voisins sont loin.
Un vote unanime peut donc concerner une région mal couverte.

Examiner les sensibilités par classe et les distances aux voisins, en complément de l'exactitude globale.

Une extrapolation limitée en régression

Avec des poids non négatifs et une somme des poids positive :

$$\min_{i \in \mathcal{N}_k(x)} y_i \leq \hat{f}_k(x) \leq \max_{i \in \mathcal{N}_k(x)} y_i$$

La prédiction est une moyenne des réponses observées dans le voisinage.

Si les réponses des voisins sont 10, 12 et 14, elle reste dans $[10, 14]$, même si une tendance suggère une valeur plus grande.

Les k-NN ne prolongent pas une tendance au-delà des réponses observées. Cette limite est importante aux bords du domaine d'entraînement.

Un coût reporté sur la prédiction

Pour chaque nouvelle observation, une recherche directe demande :

Opération	Ordre du coût
Calcul de n distances sur p variables	$O(np)$
Tri complet des distances	$O(n \log n)$
Stockage des données et des réponses	$O(np)$

Des structures de recherche peuvent accélérer le calcul, surtout en faible dimension. Leur avantage diminue souvent quand p augmente.